

Sampling

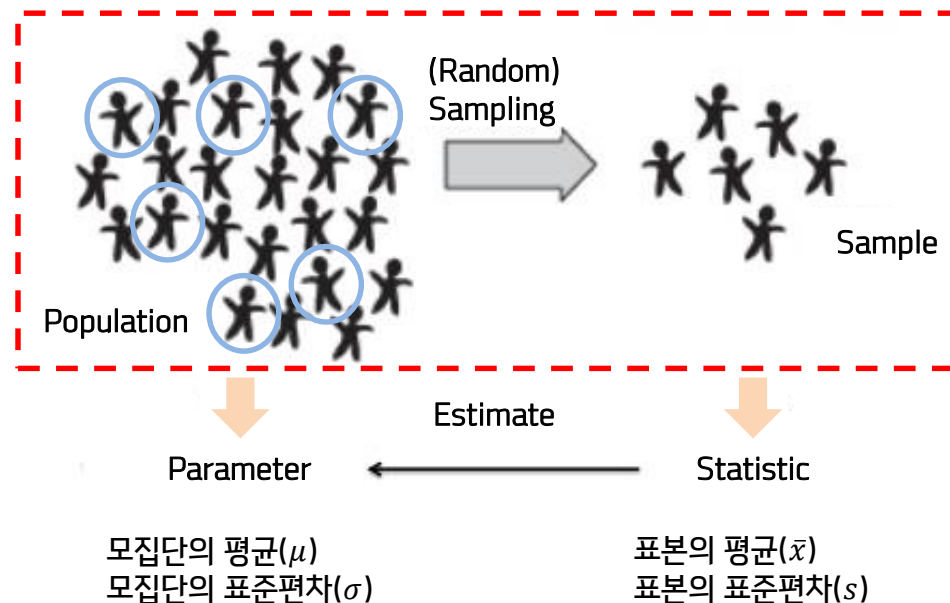
INDEX

- Simple sampling
- MCMC
- Gibbs sampling
- Metropolis Hastings algorithm

Simple sampling

❖ Sampling(표본추출)

- 모집단 전부를 대상으로 조사를 시행할 수 없을 때,
모집단의 일부를 객관적으로 추출하는 방법.

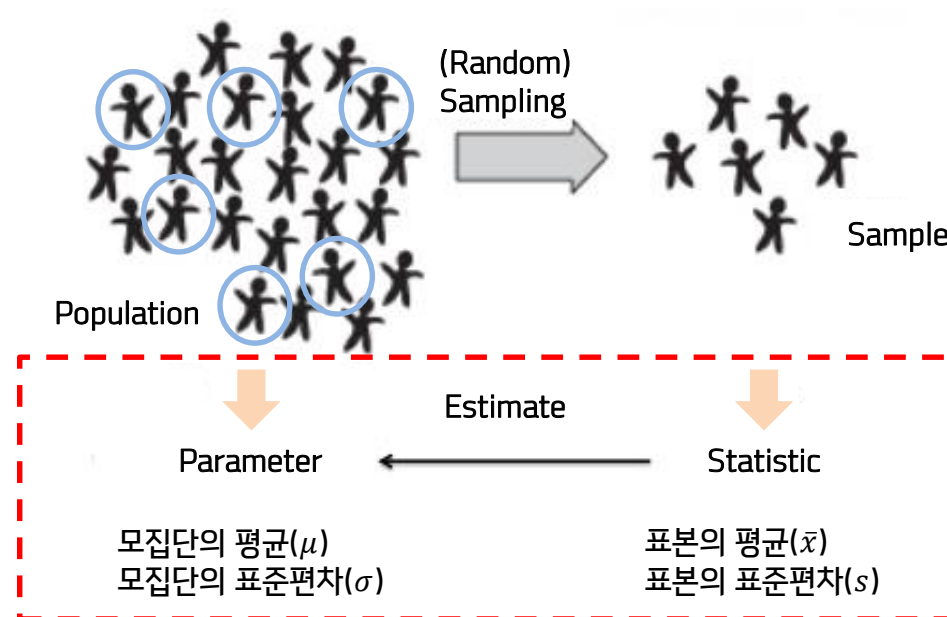


Simple sampling

❖ Sampling의 목적

- 표본에서 얻은 추정치를 이용해 모수를 알고자 함.

예) 모집단의 평균, 모집단의 표준편차, ...



Simple sampling

❖ Sample의 추정치를 구하는 방법

■ Maximum Likelihood Estimate(MLE)

- 주어진 정보에 대해 **우도를 최대화** 하는 추정치를 구함

- 우도(Likelihood function)

주어진 데이터 : x_1, x_2, \dots, x_n

구하고자 하는 모수 : $p, 0 \leq p \leq 1$

x_i : binary(동전의 앞뒤), p : 성공(1)이 나올 확률

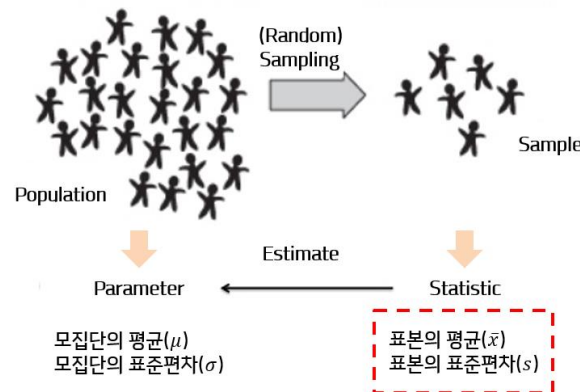
$$\begin{aligned} L(p) &= L(p; x_1, x_2, \dots, x_n) = f(x_1; p) * f(x_2; p) * \dots * f(x_n, p) \\ &= p^{\sum x_i} (1 - p)^{n - \sum x_i} \end{aligned}$$

$L(p)$ 를 최대화하는 p 값을 구한다. 보통 미분을 취해 얻을 수 있다.

- 예) 동전던지기의 결과 1, 1, 1, 0, 1이 나왔다고 하자. 이때 1이 나올 확률은?

$$\ln(L(p)) = 4 * \ln(p) + (5 - 4) * \ln(1 - p)$$

$$\frac{d \ln(L(p))}{dp} = 4 * \frac{1}{p} - 1 * \frac{1}{1-p} = 0 \quad \rightarrow \quad \hat{p} = 0.8$$



Simple sampling

❖ Sample의 추정치를 구하는 방법

▪ Least Squares Estimate(LSE)

- 적합한 모형의 예측값과 실제값과의 오차제곱합을 최소화하는 추정량을 구함

- 오차제곱합(Sum of Squared Error)_SSE

$$SSE = \sum (y - \hat{y})^2$$

오차의 제곱합을 최소화하는 모형의 parameter를 구한다. 미분으로 구할 수 있다.

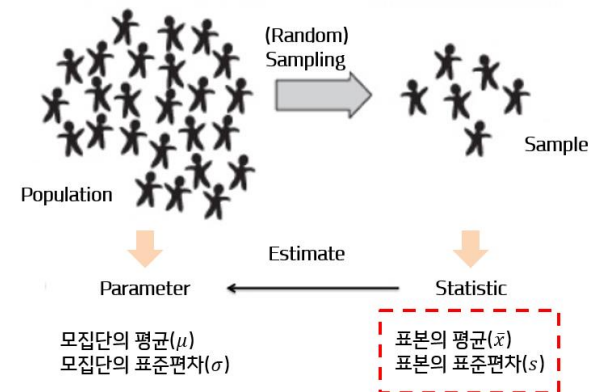
- 예) 회귀분석에서 β 를 구하는 대표적인 방법론

$$\hat{y} = \beta_0 + \beta_1 x, S(\beta_0, \beta_1) = \sum (y - \beta_0 - \beta_1 x)^2 \text{ 이다.}$$

S는 오차제곱합.

이때 S를 β_0, β_1 에 대해 각각 미분하면 S를 최소화 하는 β_0, β_1 를 구할 수 있다.

$$\beta = (X^T X)^{-1} X^T Y$$

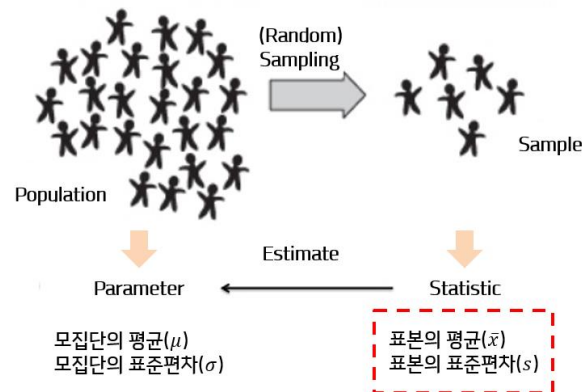



Simple sampling

❖ Sample의 추정치의 성능

- Unbiased estimator(불편추정량)

$$\text{Bias} = E(\hat{\theta}) - \theta$$



- 최소분산 불편추정량

Rao-Blackwell 정리

X_1, X_2, \dots, X_n 을 $f(x; \theta)$ 로부터의 확률표본이라 하자. $\hat{\theta} = t(X_1, X_2, \dots, X_n)$ 이 θ 에 대한 불편추정량이고 $Y = u(X_1, X_2, \dots, X_n)$ 가 θ 에 대한 충분통계량일 때

$$\phi(Y) = E(\hat{\theta}|Y)$$

는 θ 에 대해 불편추정량이고, 모든 $\theta \in \Theta$ 에 대해

$$\text{Var}_{\theta}(\phi(Y)) \leq \text{Var}_{\theta}(\hat{\theta})$$

이다.

Simple sampling


❖ Sampling 방법

▪ 난수 추출

- $U(0, 1)$ 로 부터 0부터 1사이의 실수 값 하나를 추출하고 이를 주어진 사건에 mapping해서 표본을 추출하는 방법

예) 당번 몰아주기

당번 이름	철수	영희	민수
난수 범위	(0.000, 0.333)	(0.333, 0.666)	(0.666, 1.000)

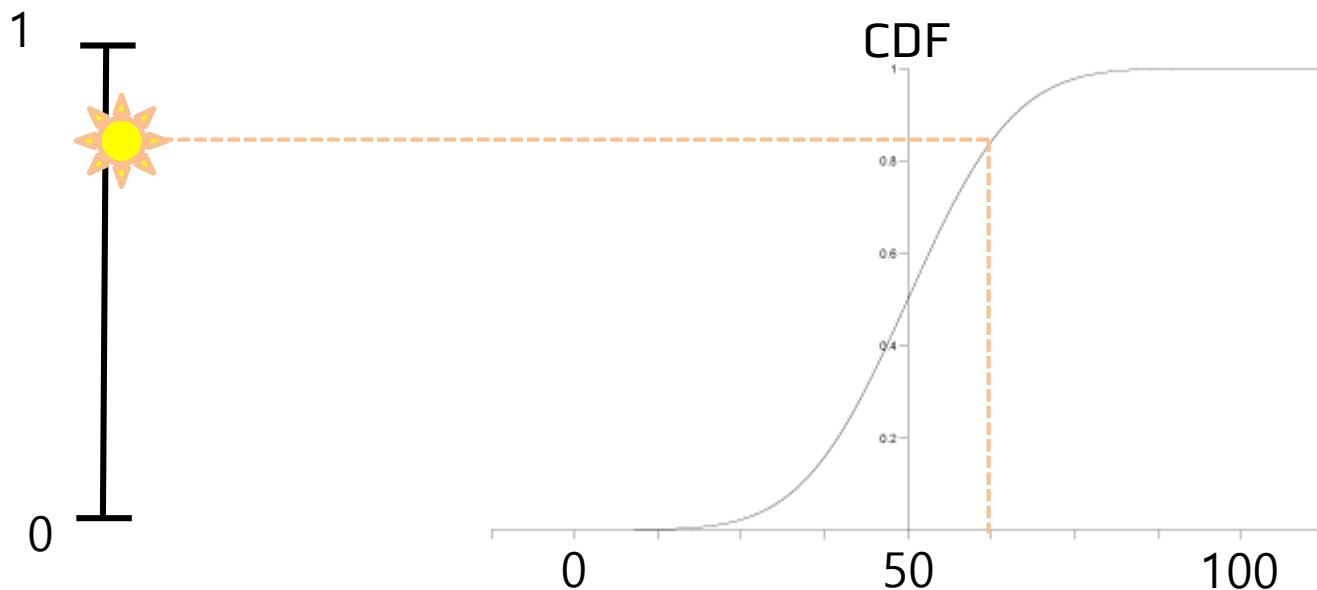


Simple sampling

❖ Sampling 방법

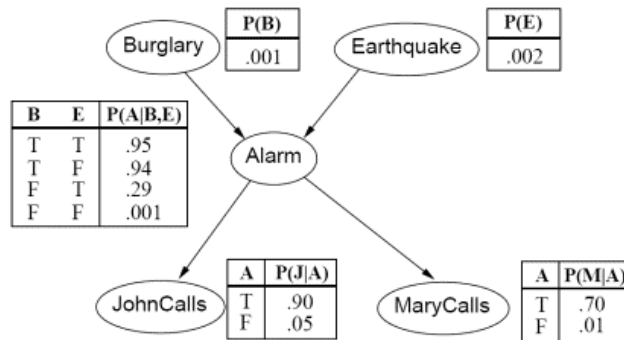
- 특정 분포를 따르는 표본 추출(Inverse CDF)
 - $U(0, 1)$ 로 부터 0부터 1사이의 실수 값 하나를 추출하고 이를 주어진 분포에 mapping해서 표본을 추출하는 방법
 - If $U \sim Unif(0, 1)$, then $X = F^{-1}(U)$ is a simulation from $f(x)$
[단, $F(x) = f(X \leq x)$, F 는 f 의 누적 확률 분포]

예) ‘신’이 이번에 만든 인간에게 어떤 능력을 $N(50, \sigma)$ 에 기반해서 주는 경우



❖ Markov Chain Monte Carlo

- Markov Chain + Monte Carlo (MCMC)
 - 목표 확률분포(Target Probability Distribution)로부터 **샘플**을 얻는 방법
- 앞의 simple sampling과 차이
 - 종속적인 고차원의 변수



- 난수 추출, inverse CDF 등을 사용하기 어렵다

❖ Markov Chain

■ 정의

- 마르코프 연쇄의 구성에 기반한 확률 분포로부터 원하는 분포의 정적(stationary) 분포를 갖는 표본을 추출하는 알고리즘의 한 부류
- 많은 단계(step)를 거친 이후(정적 분포에 수렴)의 상태에서의 표본추출은 목표로 하는 분포로부터 추출된 표본처럼 사용

■ Markov assumption

- 확률변수(random variable)가 어떤 상태(state)에 도달할 확률이 오직 바로 이전 시점의 상태(state)에만 달려있다.
- $P(X_k | X_{k-1}, X_{k-2}, \dots, X_2, X_1, X_0) = P(X_k | X_{k-1})$

■ Mixing

- 정적 분포에 수렴
- 초기값에 의존하지 않음
- sampling하기 좋은 상태에 도달했다는 의미
- 얼마나 빨리 수렴하는지가 관건. 수렴 안하는 경우도 존재

❖ Markov Chain

■ 예제

- A사(오렌지 주스)와 A'사(오렌지 주스를 다루는 A가 아닌 회사)가 있다.
- A사의 시장 점유율 : 20%, A'사의 시장 점유율 : 80%
- 초기 상태 $S_0 = (0.2 \quad 0.8)$
- A사가 광고를 진행해서 시장 점유율을 높이하고자 함(1주마다 적용)

$$\text{전이 확률 } P = \begin{matrix} & \begin{matrix} A & A' \end{matrix} \\ \begin{matrix} A \\ A' \end{matrix} & \begin{pmatrix} 0.9 & 0.1 \\ 0.7 & 0.3 \end{pmatrix} \end{matrix}$$

- $S_1 = S_0 * P = (0.2 \quad 0.8) * \begin{pmatrix} 0.9 & 0.1 \\ 0.7 & 0.3 \end{pmatrix} = (0.74 \quad 0.26)$
- $S_2 = S_1 * P = (0.74 \quad 0.26) * \begin{pmatrix} 0.9 & 0.1 \\ 0.7 & 0.3 \end{pmatrix} = (0.848 \quad 0.152)$
- $S_3 = S_2 * P = (0.8696 \quad 0.1304)$
- $S_4 = S_3 * P = (0.87392 \quad 0.12608)$
- $S_5 = S_4 * P = (0.874784 \quad 0.125216)$
- $S_{10} = S_9 * P = (0.8749999309 \quad 0.12500000691)$
- $S_k = S_{k-1} * P$
- $S = S * P \quad \Rightarrow \quad \text{수렴상태에 도달(Mixing)}$

❖ Markov Chain

★정칙 행렬★

정사각행렬 A 에 대해 A^n 의 모든 성분이 양수, 역행렬을 갖는다.

- 정적 분포(stationary distribution)에 수렴하는 조건
 - 전이행렬이 정칙(regular)인 경우 **정칙 마르코프 연쇄**(regular Markov chains)라고 부르며 이때 정적 분포에 도달할 수 있다.
- 정칙 마르코프 연쇄의 성질
 - $S = S * P$ 로 **정적 분포를 구할 수 있다.**
 - 초기행렬 S_0 에 어떤 값에 상관없이 S_k 는 정적 분포 S 에 수렴한다.
 - 전이행렬의 거듭제곱 P^k 는 하나의 행렬 \bar{P} 에 수렴한다.
- 정적 분포를 행렬연산으로 구하기
 - $S = [S_1 \ S_2] = [S_1 \ S_2] \begin{bmatrix} 0.9 & 0.1 \\ 0.7 & 0.3 \end{bmatrix} = S * P$
 - $0.9 * S_1 + 0.7 * S_2 = S_1, \ 0.1 * S_1 + 0.3 * S_2 = S_2, \ (S_1 + S_2 = 1)$
 - 연립방정식을 풀면 $S_1 = \frac{7}{8} = 0.875, S_2 = \frac{1}{8} = 0.125$


$$S_{10} = (0.8749999309 \quad 0.12500000691)$$

But, 전이가 되어, mixing되어도 근접한 표본들은 correlated.

Not i.i.d.

❖ Markov Chain

- Markov chain sample은 **i.i.d.가 아님**



- 하나의 Chain이 Mixing된 후
t시점에서의 표본과 t-1, t+1등 **가까운 시점에서의 표본은 correlated**
 - 따라서 Mixing된 후의 표본들을 모아보면 i.i.d.라고 할 수 없다
(엄밀하게는 independent가 아니기 때문일 것)
 - i.i.d.표본을 사용하는 모형에 사용할 수 없게 됨
 - 물론, Mixing 전의 표본을 사용하는 것 보다는 훨씬 낫다
- 해결 방법
 - **빠른 iteration(time)내로 Mixing**을 하면 충분히 많은 횟수 뒤에서는 correlate를 무시할 정도로 independent일 것이라 가정
 - 여러 초기값을 이용(**Monte Carlo** 방법 이용)해서
여러 chain의 정적분포에서 표본추출

❖ Monte Carol

▪ 정의

- 계산하려는 값이 복잡한 경우에 난수를 이용하여 **함수의 값을 확률적으로 (근사적으로) 계산**하는 알고리즘

▪ 식

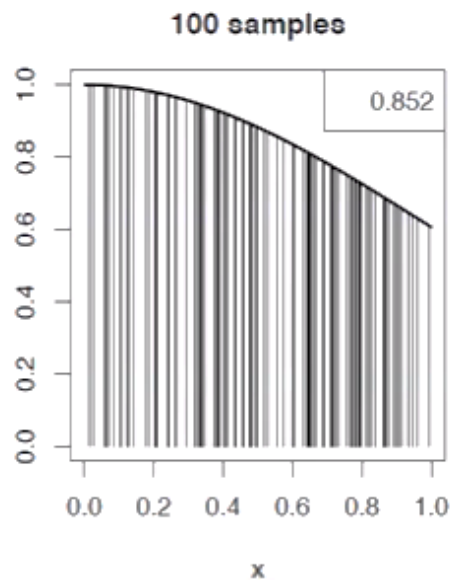

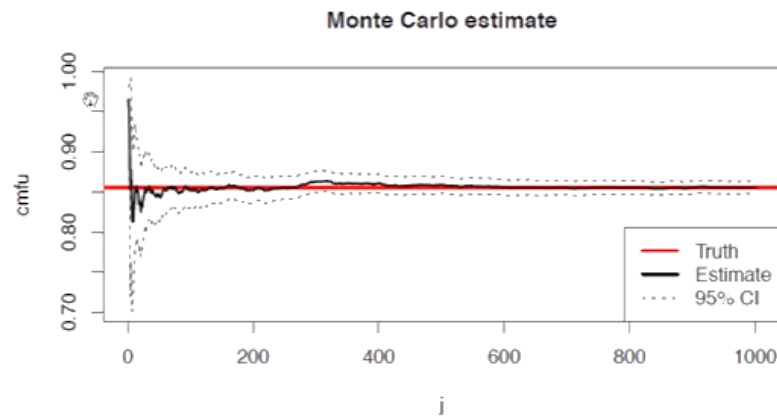
- $E_f[h(x)] = \int_x h(x)f(x)dx (= h_J)$ (계산하고 싶은 것)
- 함수 f 의 조건에서 $h(x)$ 라는 값의 모든 x 에 대한 기대 값
- 통계적 시각으로 보면 $h(x)$ 는 확률변수, f 는 확률 분포라고 생각
- $\widehat{h}_J = \frac{1}{J} \sum_{j=1}^J h(x_j)$ (몬테카를로 방법을 이용한 추정치, 근사치)
- $x_j \sim f(x), i. i. d.$ (independent and identically distributed)
- 대수의법칙(SLLN), 중심 극한 정리(CLT)에 의해 $\widehat{h}_J \rightarrow N(E_f[h(x)], v_J)$
 $(v_J = \frac{1}{J} V_f[\widehat{h(x)}] = \frac{1}{J^2} \sum_{j=1}^J [h(x_j) - \widehat{h}_J]^2)$

MCMC

❖ Monte Carol

■ 예제

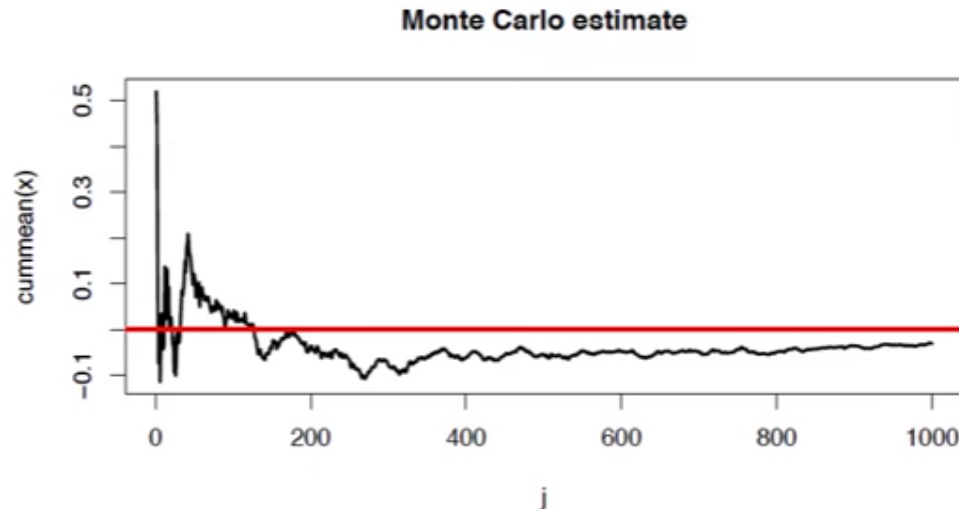
- $\int_0^1 e^{-\frac{x^2}{2}} dx$ 를 구하고자 한다
- $h(x) = e^{-\frac{x^2}{2}}$
- $f(x) = 1, X \sim Unif(0, 1)$
- $\widehat{h}_J = \frac{1}{J} \sum_{j=1}^J h(x_j)$



❖ Monte Carol

■ 예제

- $\int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$ 를 구하고자 한다
- $h(x) = x$
- $f(x) = \phi(x), x \sim N(0, 1)$
- x 가 정규분포의 평균 근처에서 많이 sampling되며 그때의 $h(x)$ 를 평균 내어 근사치를 구한다는 개념
- $\widehat{h}_J = \frac{1}{J} \sum_{j=1}^J h(x_j)$



❖ Monte Carol

▪ Bound

• Hoeffding Bound

$$P_D(\hat{h}_J \notin [h_J - \epsilon, h_J + \epsilon]) \leq 2e^{-2M\epsilon^2}$$

D : sample

\hat{h}_J : estimator

h_J : true

M : number of sample

ϵ : positive real number

$2e^{-2M\epsilon^2} < \delta$ 라는 δ (허용 오차 가능 정도)를 정의하면

$M \geq \frac{\ln(\frac{2}{\delta})}{2\epsilon^2}$ 으로 표본의 개수를 구할 수 있다.

• Chernoff Bound

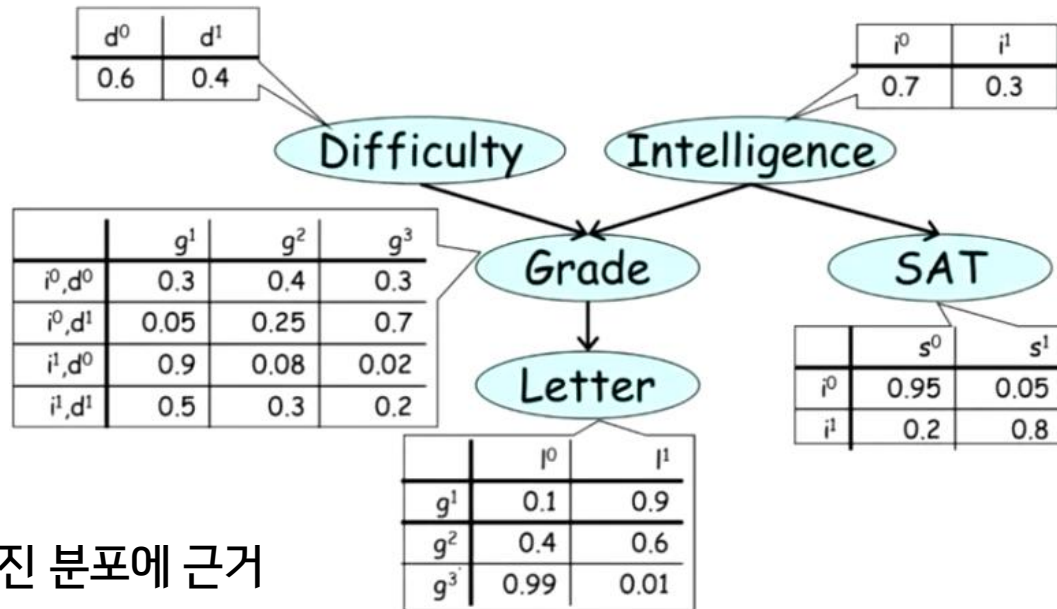
$$P_D(\hat{h}_J \notin [h_J(1 - \epsilon), h_J(1 + \epsilon)]) \leq 2e^{-\frac{Mh_J\epsilon^2}{3}}$$

$$M \geq 3 \frac{\ln(\frac{2}{\delta})}{h_J\epsilon^2}$$

MCMC

❖ Forward sampling from a BN

- 주어진 **Network에서 sampling**을 하고 싶음



- 주어진 분포에 근거
 - $(d_0, i_0, g_2, s_0, l_1)$
 - $(d_1, i_0, g_3, s_0, l_0)$
 - ...
- Goal : estimate $P(Y = y \mid E = e)$

❖ Rejection sampling


- Goal : estimate $P(Y = y \mid E = e)$
 - BN으로부터 표본을 생성
 - $E=e$ 의 조건이 맞지 않는 표본은 버림
 - $P(Y = y)$ 를 계산
- 단점
 - 표본의 결과가 **너무 적음**
 - Naïve Bayesian classifier와 같이 남성, 175cm, 73kg, 시력 1.1, 남동생 있음, 서울 거주, 고려대학교 재학, 25세, 옆구리에 점이 3개가 삼각형 모양으로 있음
 - 이런 조건을 만족하는 표본이 아니라면 사용 불가능
 - 표본이 많을 수 없음
 - 즉, 주어진 조건에 해당하는 변수의 개수가 많아짐에 따라 필요한 표본의 개수가 exponentially 증가

MCMC

❖ MCMC

- Markov Chain + Monte Carlo(초기값 다양성 및 수학적 근거 확보)
 - 목표 확률분포(Target Probability Distribution)로부터 표본을 얻는 방법
 - Markov Chain의 전이확률 P 를 MCMC 기법들을 통해 **mixing**되도록 설정, 여러 초기값 설정으로 i.i.d.를 확보한 뒤 각각의 chain에서 표본을 얻는다.

전이행렬(P)을 아는 경우



모르는 경우

(보통의 경우이다)

What?
 P 를 구한다.

How?
- Gibbs sampling
- Metropolis Hastings

MCMC

❖ MCMC

■ 장점

- 사용하기 쉽다
- 초기치에 상관없이 정적분포로 수렴하는 수학적 배경이 있다.

■ 단점

- 파라미터가 많이 필요하다.
 - 언제 Mixing 되었다고 할 수 있는가(stopping rule)
 - 몇 개의 iteration을 진행할 것인가
 - 몇 개의 표본을 추출할 것인가
- 꽤 느리게 수렴할 수 있다.
- Chain이 작동하는 것을 설명하기가 어렵다.

Gibbs sampling

❖ Gibbs sampling

■ 정의


- 두개 이상의 확률 변수의 결합 확률 분포로부터 일련의 **표본을 생성**하는 확률적 알고리즘
- Metropolis Hastings Algorithm의 특별한 예

■ Target distribution

- $P_{\Phi}(X_1, \dots, X_n)$

■ Idea


- $P_{\Phi}(X_1|X_{-1}) = P_{\Phi}(X_1|X_2, \dots, X_n)$
- 초기값 x벡터 임의로 할당
- for (i in 1:n){
 sample $x_i \sim P_{\Phi}(X_i|X_{-i})$
}
- Set $x_{new} \leftarrow x_{old}$



Gibbs sampling

❖ Gibbs sampling

▪ 예제



- $\widetilde{P}_{\Phi}(D, I, G \mid l_0, s_1)$ 에서 표본 추출
- 초기값 임의로 d_0, i_0, g_1 설정
- $P_{\Phi}(D \mid i_0, g_1, l_0, s_1)$ 에서 d_1 추출
- $P_{\Phi}(I \mid d_1, g_1, l_0, s_1)$ 에서 i_1 추출
- $P_{\Phi}(G \mid d_1, i_1, l_0, s_1)$ 에서 g_3 추출
 - d_1, i_1, g_3, l_0, s_1 이 하나의 표본이 됨
 - 이를 통해 다음 표본을 계속해서 뽑아 냄.(MCMC의 한 예로 볼 수 있다.)

Gibbs sampling

❖ Gibbs sampling

▪ 장점(계산상 이득)

• for (i in 1:n){

sample $x_i \sim P_{\Phi}(X_i | X_{-i})$

$$P_{\Phi}(X_i | X_{-i}) = \frac{P_{\Phi}(X_i, X_{-i})}{P_{\Phi}(X_{-i})} = \frac{\tilde{P}_{\Phi}(X_i, X_{-i})}{\tilde{P}_{\Phi}(X_{-i})}$$

Network에서 Factor로 생각


$$\propto \prod_{j: X_i \in \text{Scope}[C_j]} \phi_j(X_i, x_{j,-i})$$

$$P_{\Phi}(A | b, c, d)$$

$$= \frac{\tilde{P}_{\Phi}(A, b, c, d)}{\sum_{A'} \tilde{P}_{\Phi}(A', b, c, d)}$$


$$= \frac{\phi_1(A, b) \phi_2(b, c) \phi_3(c, d) \phi_4(A, d)}{\sum_{A'} \phi_1(A', b) \phi_2(b, c) \phi_3(c, d) \phi_4(A', d)}$$

$$\propto \phi_1(A, b) \phi_4(A, d)$$



Gibbs sampling

❖ XOR 문제



X_1	X_2	Y	Prob
0	0	0	0.25
0	1	1	0.25
1	0	1	0.25
1	1	0	0.25

▪ $Y=1$ 이 주어진 상황

- $x_1 = 0, x_2 = 1$ 초기 할당
 - $P(X_1 = 0 | x_2 = 1, y = 1) = 1$
 $P(X_1 = 1 | x_2 = 1, y = 1) = 0 \Rightarrow x_1 = 0$ 할당
 - $P(X_2 = 0 | x_1 = 0, y = 1) = 0$
 $P(X_2 = 1 | x_1 = 0, y = 1) = 1 \Rightarrow x_2 = 1$ 할당
 - 앞으로 수차례 진행해도 이 결과가 바뀌지 않음 (0, 1, 1)
 - 초기할당이 다른 경우에는 다른 표본이 나오지만 그 또한 **다른 상황으로 변할 여지가 없음**
 - 이는 **Non-mixing chain**이다. 다른 경우가 나올 확률이 0 (Non-regular)
 - 즉, 정적분포로 수렴하지 않으므로 표본추출이 용이하지 않다.
- Factor에 noise추가로 regular로 만들 수 있지만 좋은 방법은 아니다.
 - 위 방식으로 regular를 만들어줘도, **mixing까지 속도는 느리다.**

Gibbs sampling

❖ Summary

■ 특징

- Joint distribution에서 어려운 sampling 문제를 보다 계산이 적고 쉬운 conditional distribution에서의 sampling 문제로 변환

■ 장점

- MCMC의 가장 쉬운 예
- 계산의 이득을 많이 취함

■ 단점

- Mixing까지 오래가는 경우가 종종 있음
- Factor의 곱으로부터 sampling 할 수 있는 경우에 한해서 적용 가능

Metropolis Hastings Algorithm

❖ Metropolis Hastings Algorithm


■ 정의

- 직접적으로 표본을 얻기 어려운 확률 분포로부터 **표본의 수열을 생성**하는데 사용하는 기각 표본 추출 알고리즘
- 일반적인 적용에는 제약이 있지만 **보통 더욱 빠르고 사용하기 쉽다.**

■ Idea

- q 를 이용해 샘플링을 진행하고, a 로 방향성을 체크한 뒤 최종적으로는 f 에 근사
 - $f(x)$: target density (정적 분포에 비례하게 설정. 굳이 정규화할 필요 없다)
 - x_j : current value
 - $q(x|x_j)$: proposal distribution(아무 분포나 가능, 보통 대칭형 사용)
- Sample $x^* \sim q(x|x_j)$
 x^* 가 x_j 보다 그럴 듯 한지 확인
- Acceptance probability $a(x_j, x^*) = \min \left\{ 1, \frac{f(x^*) q(x_j|x^*)}{f(x_j) q(x^*|x_j)} \right\}$
- Set $x_{j+1} = x^*$ with probability $a(x_j, x^*)$, o.w. $x_{j+1} = x_j$
- $x_j \rightarrow X$ where $X \sim f(x)$

■ x_j 는 i.i.d.가 아니다.



Metropolis Hastings Algorithm

❖ Metropolis Hastings Algorithm

■ 도식화

- f : target density

- 주어진 Stationary distribution에 비례
 - » 정확한 분포를 알지 못함
- 가정이 필요
 - » 최대한 형태를 보존
 - » 아는 분포로 근사


- q : proposal distribution

- f 를 잘 찾아가는 것이 목표
- 가정이 필요
 - » 보통 symmetric한 분포를 가정(정규분포 등)
- 찾아가는 단계에서 표본이 나오게 되며, 이를 모아보면 f 의 형태를 따라가게 됨
- 표본은 q 에서 파라미터를 update하는 역할

- a : acceptance probability

- q 가 여기저기 움직이며 f 를 찾아다닐 때, 정확히 움직이는 것인지 아닌지 판단


■ q 와 a 의 조합(곱)이 우리가 찾고자 하는 전이행렬이다.



Metropolis Hastings Algorithm

❖ Metropolis Hastings Algorithm

- 예) 정규분포 찾아가기 (가정 : $q(x|x_j) = q(x_j|x)$, q : symmetric)
 - $a(x_j, x^*) = \min \left\{ 1, \frac{f(x^*)}{f(x_j)} \frac{q(x_j|x^*)}{q(x^*|x_j)} \right\} = \min \left\{ 1, \frac{f(x^*)}{f(x_j)} \right\}$
 - $f(x) = N(5, 9)I(1 \leq x \leq 6)$, i. e. $f(x) \propto \exp \left(-\frac{(x-5)^2}{18} \right) I(1 \leq x \leq 6)$
 - $q(x|x_j) = N(x_j, 1)$, $x_0 = 5$, q 로부터 표본 3.1이라 하자.




Metropolis Hastings Algorithm

❖ Metropolis Hastings Algorithm

▪ Reversible chain

- π : Stationary distribution, T : 전이행렬
- $\pi(i)T(i \rightarrow j) = \pi(j)T(j \rightarrow i)$
- 모든 i, j 에 대해 성립할 경우, **Detailed balance** 라고 한다.



▪ Theorem

- **Chain이 detailed balance이고 T 가 regular면 T 는 유일한 정적분포 π 를 갖는다. -> 즉, detailed balance인 T 를 찾자.**

$$\sum_i \pi(i)T(i \rightarrow j) = \sum_i \pi(j)T(j \rightarrow i) = \pi(j) \sum_i T(j \rightarrow i) = \pi(j)$$

[Stationary distribution의 정의, 정의를 다른 방식으로 보는 관점 제공]

예)

$$\begin{aligned} & \sum_i \pi(i)T(i \rightarrow 2) \\ &= \pi(2)T(2 \rightarrow 1) + \pi(2)T(2 \rightarrow 2) + \pi(2)T(2 \rightarrow 3) \\ &= \pi(2)[T(2 \rightarrow 1) + T(2 \rightarrow 2) + T(2 \rightarrow 3)] \\ &= \pi(2) \end{aligned}$$

from

to

	1	2	3
1			
2		$T(i \rightarrow j)$	
3			

Metropolis Hastings Algorithm

❖ Metropolis Hastings Chain

- Proposal distribution(q)
 - $Q(x \rightarrow x')$
- Acceptance probability(a)
 - $a(x \rightarrow x')$
- 각 상태 x 에서 x' 로 가는 상황을 Q 에 기반해서 결정
- a 가 수락을 의미하는 경우, 다음단계의 상태를 x' 로 결정해준다.
그렇지 않다면 다음단계의 상태를 계속 x 로 유지한다.
- 즉,

$$T(x \rightarrow x') = Q(x \rightarrow x')a(x \rightarrow x') \text{ if } x' \neq x$$

$$T(x \rightarrow x) = Q(x \rightarrow x) + \sum_{x' \neq x} Q(x \rightarrow x')[1 - a(x \rightarrow x')]$$

Metropolis Hastings Algorithm

❖ Acceptance probability(a)

- 만족시킬 조건 : Detailed balance

$$\pi(x)T(x \rightarrow x') = \pi(x')T(x' \rightarrow x)$$

(a는 detailed balance를 유지하는 장치)

$$\pi(x)Q(x \rightarrow x')a(x \rightarrow x') = \pi(x')Q(x' \rightarrow x)a(x' \rightarrow x)$$

$$\frac{a(x \rightarrow x')}{a(x' \rightarrow x)} = \frac{\pi(x')Q(x' \rightarrow x)}{\pi(x)Q(x \rightarrow x')} = \rho < 1$$

$$\rightarrow a(x \rightarrow x') = \rho, a(x' \rightarrow x) = 1$$

$$a(x \rightarrow x') = \min \left[1, \frac{\pi(x')Q(x' \rightarrow x)}{\pi(x)Q(x \rightarrow x')} \right]$$

Metropolis Hastings Algorithm

❖ Proposal distribution(Q)

- Q는 a 안에서 비율의 형태로 존재한다.

$$\alpha(x \rightarrow x') = \min \left[1, \frac{\pi(x')Q(x' \rightarrow x)}{\pi(x)Q(x \rightarrow x')} \right]$$

Q는 0이 되어서는 안된다. $Q(x \rightarrow x') > 0, Q(x' \rightarrow x) > 0$

- Q는 Mixing을 이루기 위해 전체를 훑어볼 수 있어야 한다.
- 하지만 너무 광범위하게 탐색하는 경우 α 가 정말 낮은 값을 갖게 될 수 있다.

Metropolis Hastings Algorithm

❖ Gibbs sampling and Metropolis Hastings Chain

■ 성능 비교

- MH의 경우 Gibbs보다 더 잘 Mixing되는 것을 확인 가능
- MH도 사용한 Q에 따라 성능 차이가 있음

